

Conalep Tepic #169

Aplicación de Modelos Predictivos

Predicción de Hospitalización de Pacientes Mediante Técnicas de Aprendizaje

Supervisado

Joseph Lemus

Cruz Sánchez Eligardo

25 de mayo de 2026

Contenido

INTRODUCCIÓN	4
MARCO TEÓRICO	5
METODOLOGIA CRISP-DM	6
COMPRENSIÓN DEL NEGOCIO	6
Contexto del problema.....	6
Objetivos del proyecto	7
Identificación del problema de minería de datos	7
Elección del modelo predictivo	8
COMPRENSIÓN DE LOS DATOS	8
Descripción del conjunto de datos.....	8
Descripción de las variables	11
PREPARACIÓN DE LOS DATOS	12
Selección de variables	12
Limpieza de los datos	12
DICCIONARIO DE DATOS	13
TRATAMIENTO DE VALORES FALTANTES	14
Transformación y estandarización de variables.....	15
Conjunto de datos final	15
MODELADO	16
Selección de algoritmos	16
División de los datos.....	16
Entrenamiento del modelo Random Forest.....	17
Entrenamiento del modelo de Regresión Logística	18

Comparación de modelos	19
EVALUACION	20
Resultados obtenidos.....	20
Comparación y análisis de resultados	20
Selección del modelo final	21
Verificación de confiabilidad	21
DESPLIEGUE	22
Aplicación potencial del modelo	22
Beneficios esperados.....	22
Limitaciones del proyecto	23
Trabajo futuro	23
CONCLUSIONES	23
REFERENCIAS	25

INTRODUCCIÓN

En la actualidad, las instituciones de salud enfrentan el desafío de administrar de manera eficiente sus recursos ante la constante demanda de atención médica. La capacidad de anticipar si un paciente requerirá hospitalización permite una mejor planificación de camas, equipamiento y personal médico, favoreciendo una atención más oportuna y una distribución más eficiente en los recursos disponibles.

El uso de técnicas de ciencia de datos permite analizar grandes volúmenes de información clínica con el propósito de identificar patrones y relaciones entre distintas variables médicas. A partir de registros históricos de pacientes, es posible entrenar modelos capaces de reconocer comportamientos recurrentes que contribuyen a la predicción de eventos futuros, como la necesidad de hospitalización.

El presente proyecto tiene como objetivo desarrollar un modelo predictivo capaz de determinar si un paciente será hospitalizado utilizando información clínica y demográfica contenida en un conjunto de datos de salud. Para lograrlo, se realizó el análisis y preparación de los datos, así como comparación de diferentes algoritmos de clasificación con el fin de identificar la alternativa que ofreciera el mejor desempeño para el problema planteado.

Para el desarrollo de este trabajo se empleó la metodología CRISP-DM (Cross Industry Estándar Process for Data Mining), la cual proporciona una estructura organizada para la ejecución de proyectos de minería de datos. Esta metodología permite abordar el problema de manera sistemática mediante fases de comprensión del negocio, comprensión

de los datos, preparación de los datos, modelado y evaluación, contribuyendo a la obtención de resultados confiables y reduciendo la posibilidad de errores durante el proceso.

MARCO TEÓRICO

La predicción de hospitalización es un problema de clasificación en el área de análisis de datos en salud, donde se busca estimar si un paciente será hospitalizado o no a partir de variables clínicas y demográficas.

En el ámbito médico, indicadores como la edad, el índice de masa corporal (IMC), la presión arterial, los niveles de glucosa, colesterol y triglicéridos son utilizados como señales importantes del estado de salud general de una persona. Estas variables permiten identificar patrones asociados a enfermedades crónicas o riesgos de complicaciones que pueden requerir hospitalización.

El aprendizaje automático (Machine Learning) es un conjunto de técnicas que permite a los sistemas aprender patrones a partir de datos históricos para realizar predicciones. En este proyecto se utiliza un enfoque de aprendizaje supervisado, específicamente una tarea de clasificación binaria, donde el objetivo es predecir dos posibles resultados: Hospitalización (1) o no hospitalizado (0).

Entre los modelos más utilizados para este tipo de problemas se encuentra la regresión logística que estima la probabilidad de pertenencia a una clase, y los modelos basados en árboles de decisión como Random Forest, que combinan múltiples árboles para mejorar la precisión y reducir el sobreajuste.

El uso de estos modelos permite analizar datos médicos de manera eficiente, apoyando la toma de decisiones en contextos de salud.

METODOLOGIA CRISP-DM

COMPRENSIÓN DEL NEGOCIO

Contexto del problema

Los hospitales enfrentan constantemente el reto de administrar sus recursos de manera eficiente para garantizar una atención medica adecuada a los pacientes. La disponibilidad de camas, equipamiento y personal medico puede verse afectada cuando la demanda de hospitalización supera las previsiones establecidas. En este contexto, la capacidad de anticipar que pacientes podrían requerir hospitalización representa una herramienta de gran valor para la planeación hospitalaria.

La identificación temprana de pacientes con alta probabilidad de hospitalización no solo beneficia a las instituciones de salud, sino también a los propios pacientes, quienes pueden recibir una atención mas oportuna y un mejor seguimiento de su condición médica. Por ello, el uso de modelos predictivos basados en informática clínica y demográfica constituye una alternativa viable para apoyar la toma de decisiones dentro del ámbito hospitalario.

Objetivos del proyecto

Objetivo general

Desarrollar un modelo predictivo capaz de determinar si un paciente será hospitalizado utilizando información clínica, demográfica y antecedentes médicos contenidos en un conjunto de datos de salud.

Objetivos específicos

- Analizar las variables presentes en el conjunto de datos para identificar la información relevante para el problema planteado.
- Identificar las variables mas relevantes para la predicción de hospitalización dentro del conjunto de datos.
- Evaluar modelos de clasificación adecuados para la predicción de hospitalización.
- Preparar el conjunto de datos mediante procesos de limpieza y transformación para mejorar la calidad de la información utilizada en el modelado.
- Comparar el desempeño de los modelos seleccionados para determinar la alternativa mas adecuada para el problema planteado.

Identificación del problema de minería de datos

El problema abordado en este proyecto consiste en predecir si un paciente será hospitalizado a partir de información clínica, demográfica y antecedentes médicos registrados en un conjunto de datos de salud. La variable objetivo-utilizada es **hospitalización**, la cual se encuentra representada de forma binaria, donde el valor 0 indica que el paciente no fue hospitalizado y el valor 1 indica que si fue hospitalizado.

Debido a que el conjunto de datos contiene ejemplos previamente etiquetados con el resultado esperado, el problema corresponde a una tarea de aprendizaje supervisado.

Asimismo, al tratarse de una variable objetivo-categorica con dos posibles resultados, la solución adecuada pertenece a la familia de modelos de clasificación, cuyo propósito es asignar nuevas observaciones a una de las categorías definidas.

Elección del modelo predictivo

Para la resolución del problema se selecciono un modelo de clasificación supervisada. Esta elección se fundamenta en que el objetivo del proyecto no consiste en predecir valores numéricos continuos ni en descubrir grupos ocultos dentro de los datos, sino en determinar a cuál de dos categorías pertenece cada paciente: hospitalizado o no hospitalizado.

Considerando la naturaleza de la variable objetivo y la disponibilidad de datos previamente etiquetados, la clasificación supervisada representa la alternativa mas adecuada para el desarrollo del modelo predictivo. Este enfoque permite utilizar la información histórica disponible para identificar patrones y relaciones entre las variables del conjunto de datos, facilitando la predicción de nuevos casos de hospitalización.

COMPRENSIÓN DE LOS DATOS

Descripción del conjunto de datos

El presente proyecto utiliza un conjunto de datos del sector salud que contiene información clínica, demográfica y antecedentes médicos de diversos pacientes. Dicho conjunto de datos fue proporcionado con el propósito de desarrollar un modelo predictivo capaz de determinar

si un paciente será hospitalizado a partir de las características registradas en cada observación.

Variable	Tipo de dato (original)	Descripción
id_paciente	Numérico / Entero	Identificador único del paciente
edad	Numérico	Edad del paciente en años
sexo	Categórico	Sexo del paciente (valores originales como M, F, FEM, H)
municipio	Categórico	Municipio de residencia del paciente
tipo_seguro	Categórico	Tipo de seguro o afiliación médica (puede contener texto adicional como “/ Bienestar”)
peso_kg	Numérico	Peso del paciente en kilogramos
talla_cm	Numérico	Estatura del paciente en centímetros
imc	Numérico	Índice de masa corporal
presion_sistolica	Numérico	Presión arterial sistólica
presion_diastolica	Numérico	Presión arterial diastólica
colesterol_mg_dl	Numérico	Nivel de colesterol en sangre
trigliceridos_mg_dl	Numérico	Nivel de triglicéridos en sangre
hemoglobina_g_dl	Numérico	Nivel de hemoglobina en sangre
glucosa_mg_dl	Numérico	Nivel de glucosa en sangre
creatinina_mg_dl	Numérico	Nivel de creatinina
urea_mg_dl	Numérico	Nivel de urea en sangre

num_medicamentos_actuales	Numérico	Cantidad de medicamentos que consume el paciente
escolaridad	Categorico	Nivel educativo del paciente (con variaciones de escritura)
ocupación	Categorico	Actividad laboral del paciente
antecedentes_familiares	Categorico	Presencia de antecedentes familiares de enfermedades
diabetes	Categorico	Diagnóstico de diabetes (SI/NO o variantes originales)
hipertensión	Categorico	Diagnóstico de hipertensión
tabaquismo	Categorico	Consumo de tabaco
alcoholismo	Categorico	Consumo de alcohol
hospitalizacion	Binaria (0/1)	Variable objetivo: 1 = hospitalizado, 0 = no hospitalizado
fecha_registro	Fecha	Fecha en que se registró el paciente
servicio_medico	Categorico	Servicio o área médica de atención

El diccionario de datos permite identificar y comprender las variables disponibles en el conjunto de datos, así como su tipo y significado dentro del contexto del problema. Esta información es fundamental para la etapa de preparación de datos, ya que facilita la selección de variables relevantes para el modelo predictivo.

La información disponible incluye variables relacionadas con datos personales, indicadores de salud, antecedentes clínicos y hábitos de vida, así como una variable objetivo denominada **hospitalización**, utilizada para entrenar y evaluar los modelos predictivos desarrollados durante el proyecto.

Descripción de las variables

El conjunto de datos esta conformado por variables de naturaleza numérica y categórica que describen diferentes aspectos de los pacientes. Estas variables incluyen información demográfica, indicadores clínicos, antecedentes médicos y hábitos relacionados con la salud.

Entre las variables mas relevantes se encuentran la edad del paciente, el índice de masa corporal (IMC), los niveles de glucosa, colesterol, y triglicéridos, así como antecedentes de enfermedades como diabetes, hipertensión y cardiopatías. De igual forma se consideran variables relacionadas con hábitos de vida, como el consumo de alcohol, tabaquismo y actividad física.

La variable objetivo-utilizada en el proyecto corresponde a **hospitalización**, la cual fue representada de forma binaria, donde el valor **0** indica que el paciente no fue hospitalizado y el valor **1** indica que si fue hospitalizado. Esta variable constituye el elemento que los modelos de clasificación intentan predecir a partir del resto de las características disponibles.

PREPARACIÓN DE LOS DATOS

Selección de variables

Antes de entrenar los modelos predictivos, se realizó un proceso de análisis de las variables disponibles con el propósito de identificar aquellas que aportaban información relevante para la predicción de hospitalización. Durante esta etapa se evaluó la utilidad de cada atributo considerando su relación con el problema planteado y su posible contribución al desempeño del modelo.

Como resultado de este análisis, se descartaron variables que no aportaban valor significativo al proceso de predicción o cuya información resultaba redundante para el objetivo del proyecto. Esta elección permitió trabajar con un conjunto de datos mas consistente y enfocado en las características de interés.

Se seleccionaron variables relacionadas con el estado clínico del paciente, como edad presión arterial, glucosa, colesterol y antecedentes médicos, debido a que estas características tienen una relación directa con el riesgo de hospitalización.

Se excluyeron variables como identificadores únicos o campos no predictivos, ya que no aportan información relevante al modelo y podrían introducir ruido en el análisis.

Limpieza de los datos

Con el fin de mejorar la calidad de la información, se llevó a cabo un proceso de limpieza de datos orientado a corregir inconsistencias presentes en el conjunto de datos.

Entre las acciones realizadas se incluyeron la eliminación de espacios innecesarios, la normalización de textos y la corrección de formatos inconsistentes dentro de distintas variables categóricas.

Asimismo, se corrigieron diferencias en la representación de categorías equivalentes, unificando valores que representaban la misma información pero que se encontraban escritos de formas distintas. Este proceso permitió reducir errores y mejorar la consistencia general del conjunto de datos.

Se realizó la limpieza de datos con el objetivo de corregir inconsistencias, valores faltantes y registros incorrectos que podrían afectar el desempeño del modelo. La estandarización de variables permitió asegurar coherencia en el conjunto de datos.

DICCIONARIO DE DATOS

Variable	Tipo de dato	Descripción
hospitalización	Binaria (0/1)	Variable objetivo. Indica si el paciente fue hospitalizado (1) o no (0).
edad	Numérica (entera)	Edad del paciente en años. Se eliminaron valores imposibles o inconsistentes.
sexo	Categórica	Sexo del paciente (M/F), normalizado desde diferentes formatos originales.
peso_kg	Numérica (continua)	Peso del paciente en kilogramos. Contiene valores imputados en algunos casos.
talla_cm	Numérica (continua)	Estatura del paciente en centímetros.

imc	Numérica (continua)	Índice de masa corporal calculado a partir de peso y talla.
presion_sistolica	Numérica	Presión arterial sistólica del paciente.
presion_diastolica	Numérica	Presión arterial diastólica del paciente.
colesterol_mg_dl	Numérica	Nivel de colesterol en sangre (mg/dL).
trigliceridos_mg_dl	Numérica	Nivel de triglicéridos en sangre (mg/dL).
hemoglobina_g_dl	Numérica	Nivel de hemoglobina en sangre (g/dL).
glucosa_mg_dl	Numérica	Nivel de glucosa en sangre (mg/dL).
tipo_seguro	Categórica	Tipo de seguro médico del paciente, normalizado y depurado.
escolaridad	Categórica	Nivel educativo del paciente.
ocupación	Categórica	Ocupación del paciente.
num_medicamentos_actuales	Numérica (entera)	Número de medicamentos que el paciente consume actualmente.

TRATAMIENTO DE VALORES FALTANTES

Durante la exploración inicial de los datos se identificó la presencia de valores faltantes en diversas variables. Para garantizar la calidad del conjunto de datos utilizando en el modelado, se aplicaron estrategias de tratamiento adecuadas según la naturaleza de cada variable.

En algunos casos se eliminaron registros que contenían información insuficiente para el análisis, mientras que en otros se utilizaron técnicas de sustitución mediante valores representativos de la distribución de los datos. Estas acciones permitieron minimizar la pérdida de información y reducir el impacto de los datos incompletos sobre el desempeño de los modelos predictivos.

Se aplicó escalado de variables numéricas para evitar que aquellas con mayores magnitudes dominaran el modelo. Asimismo, se realizó la división en conjunto de entrenamiento y prueba para evaluar la capacidad de generalización del modelo.

Transformación y estandarización de variables

Posteriormente, se realizaron diversas transformaciones orientadas a preparar la información para su utilización en los algoritmos de clasificación. Entre estas transformaciones se incluyó la normalización de categorías, la unificación de respuestas binarias y la corrección de valores categóricos inconsistentes.

De igual manera, la variable objetivo fue representada mediante una codificación binaria, donde el valor 0 corresponde a pacientes no hospitalizados y el valor 1 a pacientes hospitalizados. Estas transformaciones permitieron obtener un conjunto de datos homogéneo y adecuado para el proceso de modelado.

Conjunto de datos final

Una vez concluidas las etapas de selección, limpieza y transformación de datos, se obtuvo un conjunto de datos depurado y preparado para el entrenamiento de los modelos predictivos. La información final conservó únicamente las variables consideradas relevantes

para el problema de estudio y presento un formato consistente que permitió su utilización en las fases posteriores de modelado y evaluación.

```
=====
DATASET CARGADO Y LIMPIO
=====
Total de registros: 994
Hospitalizados (1): 377
No hospitalizados (0): 617

Variables categóricas: 11
Variables numéricas: 11

✓ Columnas en el orden correcto: 22 columnas

Tamaño entrenamiento: 795 registros
Tamaño prueba: 199 registros
Proporción hospitalizados en entrenamiento: 37.99%
```

MODELADO

Selección de algoritmos

Una vez definido el problema como una tarea de clasificación supervisada, se seleccionaron los algoritmos Regresión Logística y Random Forest. Ambos son ampliamente utilizados en problemas de clasificación binaria y permiten identificar patrones dentro de los datos para realizar predicciones.

La selección de estos algoritmos tuvo como objetivo comparar diferentes enfoques de clasificación y determinar cuál ofrecía mejores resultados para la predicción de hospitalización.

División de los datos

El conjunto de datos fue dividido en dos subconjuntos: entrenamiento y prueba. Se utilizó el 80% de los registros para entrenamiento y el 20% para prueba, manteniendo la

proporción de pacientes hospitalizados y no hospitalizados mediante una división estratificada.

Esta estrategia permitió entrenar los modelos con la mayor cantidad de información posible y evaluar posteriormente su capacidad de generalización utilizando datos vistos previamente.

```
# División train/test
X_train, X_test, y_train, y_test = train_test_split(
    X_scaled, y, test_size=0.2, random_state=42, stratify=y
)

print(f"\nTamaño entrenamiento: {X_train.shape[0]} registros")
print(f"Tamaño prueba: {X_test.shape[0]} registros")
print(f"Proporción hospitalizados en entrenamiento: {y_train.mean():.2%}")
```

Entrenamiento del modelo Random Forest

Se entreno un modelo Random Forest utilizando el conjunto de entrenamientos. Este algoritmo genera múltiples arboles de decisión y combina sus resultados para producir una predicción final, permitiendo reducir errores y mejorar la estabilidad del modelo.

Una vez finalizado el entrenamiento, se realizaron predicciones sobre el conjunto de prueba para obtener las métricas de desempeño correspondientes.

```
# Entrenar modelo
rf_model = RandomForestClassifier(
    n_estimators=100,
    max_depth=10,
    min_samples_split=5,
    min_samples_leaf=2,
    random_state=42,
    class_weight='balanced'
)

start_time = time.time()
rf_model.fit(X_train, y_train)
rf_time = time.time() - start_time
```

```

=====
ENTRENANDO RANDOM FOREST
=====

=== RANDOM FOREST - RESULTADOS ===
✓ Accuracy: 0.7487
✓ Precision: 0.6712
✓ Recall: 0.6533
✓ F1-Score: 0.6622
✓ AUC-ROC: 0.8035
🕒 Tiempo de entrenamiento: 0.2914 segundos

```

Entrenamiento del modelo de Regresión Logística

También se entreno un modelo de Regresión Logística utilizando las mismas condiciones de entrenamiento y prueba. Este algoritmo permite estimar la probabilidad de que un paciente pertenezca a una determinada categoría a partir de las variables disponibles.

Posteriormente, se evaluó el modelo sobre el conjunto de prueba para obtener métricas comparables con las del modelo Random Forest.

```

# Entrenar modelo
lr_model = LogisticRegression(
    C=1.0,
    class_weight='balanced',
    max_iter=1000,
    random_state=42,
    solver='liblinear'
)

start_time = time.time()
lr_model.fit(X_train, y_train)
lr_time = time.time() - start_time

```

```
=====
ENTRENANDO REGRESIÓN LOGÍSTICA
=====
```

```
=== REGRESIÓN LOGÍSTICA - RESULTADOS ===
✓ Accuracy: 0.7638
✓ Precision: 0.6628
✓ Recall: 0.7600
✓ F1-Score: 0.7081
✓ AUC-ROC: 0.8357
🕒 Tiempo de entrenamiento: 0.0069 segundos
```

Comparación de modelos

Con el propósito de identificar el algoritmo mas adecuado para el problema planteado, se compararon los resultados obtenidos por ambos modelos utilizando las mismas condiciones de entrenamiento y evaluación.

Para realizar la comparación se utilizaron distintas métricas de clasificación. La métrica **Accuracy** representa el porcentaje total de predicciones correctas realizadas por el modelo. **Precisión** indica que tan precisas fueron las predicciones positivas realizadas. **Recall** mide la capacidad del modelo para identificar correctamente los casos positivos mientras que **F1-Score** combina Precisión y Recall en una única métrica de desempeño.

Estas métricas permiten evaluar distintos aspectos del comportamiento de los modelos y proporcionan una base objetiva para determinar cual ofrece mejores resultados en la predicción de hospitalización. El análisis detallado de los resultados obtenidos se presenta en la fase de evaluación.

EVALUACION

Resultados obtenidos

Una vez finalizado el entrenamiento de ambos algoritmos, se evaluó su desempeño utilizando el conjunto de prueba. Los resultados obtenidos se muestran en la siguiente tabla:

COMPARACIÓN DE MÉTRICAS - RANDOM FOREST vs REGRESIÓN LOGÍSTICA				
Modelo	Accuracy	Precision	Recall	F1-score
Regresión Logística	0.7638	0.6628	0.7600	0.7081
Random Forest	0.7487	0.6712	0.6533	0.6622
RESULTADOS EN PORCENTAJES:				

Regresión Logística:	Accuracy=76.4%	Precision=66.3%	Recall=76.0%	F1=70.8%
Random Forest:	Accuracy=74.9%	Precision=67.1%	Recall=65.3%	F1=66.2%

Comparación y análisis de resultados

Al comparar los resultados obtenidos por ambos algoritmos, se observa que la Regresión Logística alcanzo un Accuracy superior al obtenido por Random Forest, logrando clasificar correctamente un mayor porcentaje de pacientes.

Aunque Random Forest presento una precisión ligeramente superior, la diferencia observada fue mínima. Por otra parte, la Regresión Logística obtuvo mejores resultados en Recall y F1-Score, lo que indica una mayor capacidad para identificar correctamente a los pacientes hospitalizados y un mejor equilibrio general entre precisión y detección de casos positivos.

Considerando que el objetivo principal del proyecto consiste en predecir que pacientes podrían requerir hospitalización, resulta especialmente importante minimizar los

casos positivos no detectados. En este grupo, la Regresión Logística mostro un mejor desempeño al identificar una mayor proporción de pacientes hospitalizados.

Selección del modelo final

Con base en los resultados obtenidos durante la evaluación, se selecciono la Regresión Logística como modelo final para el problema de predicción de hospitalización.

Esta decisión se fundamente en que obtuvo los mejores resultados en Accuracy, Recall y F1-Score, métricas que permiten evaluar tanto la capacidad general de clasificación como la detección correcta de pacientes hospitalizados. Asimismo, presento un desempeño mas equilibrado entre las métricas analizadas, lo que la convierte en la alternativa mas adecuada para el conjunto de datos utilizados.

La capacidad del modelo para identificar correctamente pacientes con riesgo de hospitalización puede contribuir a una mejor planificación de recursos médicos y una atención mas oportuna dentro del entorno hospitalario.

Verificación de confiabilidad

La confiabilidad del modelo fue verificada mediante la evaluación sobre un conjunto de prueba independiente al utilizado durante el entrenamiento. Esta metodología permite medir el desempeño del algoritmo sobre datos que no fueron vistos previamente, proporcionando una estimación mas realista de su capacidad de generalización.

Además, la comparación con un segundo algoritmo permitió validar los resultados obtenidos y comprobar que la Regresión Logística ofreció un mejor desempeño para este problema específico. Por lo tanto, se considera que el modelo seleccionado presenta un

nivel de confiabilidad adecuado para apoyar la predicción de hospitalización dentro del contexto analizado.

DESPLIEGUE

Aplicación potencial del modelo

El modelo predictivo desarrollado tiene el potencial de ser utilizado como una herramienta de apoyo para la toma de decisiones dentro del sector salud. Mediante el análisis de información clínica y demográfica de los pacientes, podría contribuir a identificar aquellos casos con mayor probabilidad de requerir hospitalización.

La información generada por el modelo permitiría anticipar necesidades relacionadas con la disponibilidad de camas, personal medico y equipamiento hospitalario, favoreciendo una mejor planificación de recursos y una atención mas eficiente a los pacientes.

Beneficios esperados

La implementación de un sistema de predicción de hospitalización podría generar diversos beneficios para las instituciones de salud y para los pacientes. Entre los principales beneficios se encuentran:

- Mejor planificación de la disponibilidad de camas hospitalarias.
- Optimización del uso de recursos médicos y equipamiento
- Preparación anticipada del personal de salud para la atención de pacientes con mayor riesgo.
- Atención mas oportuna para pacientes con probabilidad de hospitalización

- Apoyo en la toma de decisiones basada en datos.

Limitaciones del proyecto

Es importante considerar que el modelo fue desarrollado utilizando un conjunto de datos específico, por lo que su desempeño puede variar al aplicarse en otros contextos o poblaciones diferentes.

Asimismo, los resultados obtenidos dependen de la calidad y representatividad de los datos utilizados durante el entrenamiento. Por esta razón, antes de una implementación real sería necesario realizar pruebas adicionales y actualizar periódicamente el modelo con información más reciente.

Trabajo futuro

Como trabajo futuro, se recomienda ampliar el conjunto de datos utilizado para el entrenamiento e incorporar nuevas variables que puedan mejorar la capacidad predictiva del modelo.

Además, podrían evaluarse otros algoritmos de clasificación y realizar procesos de optimización de hiperparámetros con el objetivo de incrementar el desempeño obtenido. Finalmente, una posible evolución del proyecto sería integrar el modelo dentro de un sistema informático que permita realizar las predicciones de manera automática para apoyar la gestión hospitalaria.

CONCLUSIONES

El presente proyecto tuvo como objetivo desarrollar un modelo predictivo capaz de identificar si un paciente podría requerir hospitalización a partir de información clínica,

demográfica y de antecedentes médicos. Para lograrlo, se siguió la metodología CRISPDM, la cual permitió organizar de manera estructurada cada una de las etapas del proceso, desde la comprensión del problema hasta la evaluación de los resultados obtenidos.

Durante el desarrollo del proyecto se realizó un proceso de selección, limpieza y preparación de los datos con el fin de garantizar la calidad de la información utilizada. Posteriormente, se implementaron dos algoritmos de clasificación supervisada: Regresión Logística y Random Forest, los cuales fueron entrenados y evaluados utilizando las mismas condiciones para permitir una comparación objetiva de su desempeño.

Los resultados obtenidos demostraron que la Regresión Logística presentó un mejor desempeño general al alcanzar valores superiores en Accuracy, Recall y F1-Score. Esto indica una mayor capacidad para identificar correctamente a los pacientes con probabilidad de hospitalización, aspecto especialmente importante dentro del contexto del problema planteado.

Finalmente, se concluye que los modelos predictivos representan una herramienta valiosa para apoyar la toma de decisiones en el sector salud. Su aplicación podría contribuir a una mejor planificación de recursos hospitalarios, una preparación más eficiente del personal médico y una atención más oportuna para los pacientes con mayor riesgo de hospitalización.

REFERENCIAS

Python. (2025). *Python Documentation*. <https://docs.python.org/3/>

pandas. (2025). *pandas documentation*. <https://pandas.pydata.org/docs/>

scikit-learn. (2025). *scikit-learn: Machine Learning in Python*. <https://scikitlearn.org/stable/>

NumPy. (2025). *NumPy Documentation*. <https://numpy.org/doc/>

Matplotlib. (2025). *Matplotlib Documentation*. <https://matplotlib.org/stable/>

CRISP-DM. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.